

Universidade Santa Cecília

Engenharia da Computação

Davi Xavier de Lima - 215011

Kauã Santos Silva - 221263

Rafael Luiz Forssell Ferrara Fomin – 213513

Totem de Autoatendimento com Recursos de Acessibilidade para Pessoas com
Deficiência Visual

Santos – SP

2025

Davi Xavier de Lima - 215011
Kauã Santos Silva - 221263
Rafael Luiz Forssell Ferrara Fomin – 213513

Totem de Autoatendimento com Recursos de Acessibilidade para Pessoas com
Deficiência Visual

Projeto apresentado como requisito parcial
para contabilização da nota de projeto, Orientador: Sergio Schina de
Andrade

Santos – SP
2025

SUMÁRIO

1	Resumo.....	5
2	Introdução.....	6
3	Justificativa.....	7
4	Objetivo Geral.....	8
5	Objetivo Específico.....	9
6	Referencial Teórico.....	10
6.1	Inteligência Artificial (IA).....	10
6.2	Modelos de Linguagem (LLM).....	10
6.3	RAG – Retrieval-Augmented Generation.....	10
6.4	CAG – Context-AwareGeneration.....	10
6.5	STT – Speech-to-Text.....	11
6.6	TTS – Text-to-Speech.....	11
6.7	Totens de Autoatendimento.....	11
6.8	Acessibilidade.....	11
7	Metodologia.....	12
7.1	Levantamento de Requisitos Técnicos e Funcionais.....	12
7.2	Seleção das Tecnologias.....	12
7.3	Estruturação do Banco de Dados (SQLite).....	12
7.4	Implementação da Camada CAG (Context-Aware Generation).....	12
7.5	Integração do LLM (Llama 3.1).....	13
7.6	Implementação dos Módulos de Entrada e Saída de Áudio.....	13
7.7	Desenvolvimento do Backend (FastAPI).....	13
7.8	Desenvolvimento do Frontend (HTML/JS).....	13
7.9	Integração do Protótipo.....	13
7.10	Testes Funcionais e Critérios de Avaliação.....	14
7.11	Documentação das Etapas.....	14
8	Arquitetura do Sistema.....	15
8.1	Camada de Entrada – Captura de Áudio.....	15
8.2	Módulo de Reconhecimento de Fala (STT – Whisper).....	16
8.3	Mecanismo de Busca Inteligente (RAG).....	16
8.4	Camada de Interpretação de Contexto (CAG).....	16
8.5	Modelo de Linguagem (LLM – Llama 3.1).....	16

8.6 Banco de Dados de Produtos (SQLite).....	16
8.7 Base Vetorial (Chroma).....	17
8.8 Módulo de Síntese de Voz (TTS – Coqui TTS).....	17
8.9 Camada de Saída – Interface do Totem.....	17
8.10 Backend (FastAPI) como Núcleo de Integração.....	17
9 Cronograma do Projeto.....	18
9.1 Janeiro – Planejamento e Definição do Escopo.....	18
9.2 Fevereiro – Pesquisa e Fundamentação Teórica.....	18
9.3 Março – Arquitetura do Sistema e Modelagem Técnica.....	18
9.4 Abril – Desenvolvimento dos Módulos Individuais.....	18
9.5 Maio – Desenvolvimento da Interface e Integração Inicial.....	18
9.6 Junho – Integração Completa do Protótipo.....	19
9.7 Julho – Testes Avançados e Refinamentos.....	19
9.8 Agosto – Documentação Final e Preparação da Banca.....	19
10 Considerações Finais.....	20
11 Referências Bibliográficas.....	21

1 RESUMO

O projeto propõe o desenvolvimento de um totem de autoatendimento acessível, voltado para auxiliar clientes, especialmente pessoas com deficiência visual, na localização de produtos dentro de lojas físicas. A solução utiliza tecnologias de Inteligência Artificial, incluindo reconhecimento de voz (STT), recuperação de informações via RAG, um modelo de linguagem LLM para interpretação das consultas e síntese de voz (TTS) para comunicação verbal com o usuário. O sistema funcionará de forma local, sem depender de internet, integrando banco de produtos, interface em tela touch e respostas por voz, proporcionando autonomia, inclusão e maior eficiência no atendimento ao cliente

2 INTRODUÇÃO

A dificuldade de localizar produtos em lojas físicas é um desafio recorrente para muitos clientes, especialmente para pessoas com deficiência visual. A dependência de atendentes, a falta de informações claras e a ausência de soluções acessíveis limitam a autonomia desses usuários durante a experiência de compra. Nesse cenário, tecnologias de Inteligência Artificial têm se mostrado uma alternativa eficiente para tornar o ambiente comercial mais inclusivo e funcional.

Este projeto apresenta o desenvolvimento de um totem de autoatendimento acessível, capaz de auxiliar clientes na identificação e localização de produtos por meio de interação por voz. A proposta integra recursos de reconhecimento de fala, recuperação de informações e síntese de voz, permitindo que o usuário realize consultas de maneira natural e sem barreiras visuais.

A iniciativa busca atender tanto o público geral quanto, de forma especial, pessoas com deficiência visual, promovendo maior independência, redução do tempo de busca e melhoria na experiência de compra. Por meio de uma abordagem técnica baseada em modelos de linguagem, processamento de áudio e banco de dados local, o projeto visa construir uma solução prática, escalável e alinhada às necessidades reais do ambiente varejista.

3 JUSTIFICATIVA

A adoção de tecnologias acessíveis no varejo ainda é limitada, o que gera barreiras significativas para clientes com deficiência visual ou dificuldades de mobilidade. Em muitos estabelecimentos, a localização de produtos depende exclusivamente da ajuda de atendentes, o que reduz a autonomia dos consumidores e pode resultar em experiências de compra demoradas, frustrantes ou pouco inclusivas.

Este projeto é importante porque propõe uma solução prática e acessível para ampliar a independência dos usuários dentro da loja, oferecendo uma forma clara, rápida e intuitiva de obter informações sobre produtos apenas por comando de voz. A integração de reconhecimento de fala, recuperação inteligente de informações e síntese de áudio permite que o totem responda de forma natural e compreensível, atendendo diretamente às necessidades de pessoas com deficiência visual.

Além de promover inclusão social, o sistema também beneficia o varejo ao otimizar o fluxo de atendimento, reduzir demandas repetitivas aos funcionários e melhorar a experiência geral do cliente. O impacto esperado envolve maior acessibilidade, aumento na satisfação do público e fortalecimento da responsabilidade social das empresas que adotarem a tecnologia.

4 OBJETIVO GERAL

Desenvolver um totem de autoatendimento acessível, capaz de auxiliar clientes na busca, identificação e localização de produtos dentro de lojas físicas por meio de interação por voz, integrando tecnologias de Inteligência Artificial como reconhecimento de fala (STT), recuperação de informações via RAG, modelo de linguagem (LLM) e síntese de voz (TTS). O sistema incluirá também uma camada CAG (Context-Aware Generation), responsável por interpretar o contexto da consulta, aplicar regras de decisão e oferecer respostas mais precisas, inclusive sugerindo alternativas quando o item solicitado não estiver disponível. O objetivo central é fornecer uma solução que compreenda comandos de voz, consulte um banco de produtos local, processe o contexto da busca e apresente respostas claras por meio de áudio e interface visual, promovendo autonomia, inclusão e uma experiência de compra mais eficiente para todos os usuários, com foco especial em pessoas com deficiência visual.

5 OBJETIVO ESPECÍFICO

- 1** Implementar o módulo de reconhecimento de fala (STT) utilizando Whisper para converter comandos de voz dos usuários em texto de forma precisa e acessível.
- 2** Estruturar o banco de produtos em SQLite, contendo informações como nome, cor, tamanho, categoria, preço e localização física dentro da loja.
- 3** Criar e configurar a base vetorial utilizando Chroma, responsável por armazenar embeddings e permitir buscas por similaridade através da técnica RAG.
- 4** Desenvolver a camada CAG (Context-Aware Generation), responsável por interpretar o contexto das consultas, aplicar regras de decisão e sugerir alternativas quando o produto solicitado não estiver disponível.
- 5** Integrar o modelo de linguagem Llama 3.1 para interpretar os resultados do RAG e do CAG, gerando respostas estruturadas e claras ao usuário.
- 6** Implementar o módulo de síntese de voz (TTS) utilizando Coqui TTS para transformar as respostas do sistema em áudio de forma natural e compreensível.
- 7** Criar o backend do sistema com FastAPI, integrando todos os módulos de IA, banco de dados e lógica de negócio para garantir comunicação eficiente com o frontend.
- 8** Desenvolver o frontend em HTML e JavaScript em modo fullscreen com suporte a tela touch, exibindo informações de forma acessível e permitindo interação simples e intuitiva.
- 9** Construir o fluxo completo de consulta, desde a captura do áudio até a entrega da resposta em texto e voz, garantindo acessibilidade e usabilidade.
- 10** Validar o protótipo com testes funcionais, avaliando a precisão do STT, a relevância dos resultados do RAG, o comportamento da camada CAG e a clareza das respostas geradas pelo LLM e pelo TTS.
- 11** Documentar todas as etapas do desenvolvimento, arquitetura, decisões técnicas e testes realizados, garantindo rastreabilidade e possibilitando evolução futura do projeto.

6 REFERENCIAL TEÓRICO

6.1 Inteligência Artificial (IA)

A Inteligência Artificial compreende um conjunto de técnicas capazes de simular características cognitivas humanas, como percepção, reconhecimento de padrões, tomada de decisão e compreensão de linguagem. No contexto deste projeto, a IA é aplicada para interpretar comandos de voz, recuperar informações relevantes de um banco de dados e gerar respostas compreensíveis ao usuário, proporcionando uma interação natural e acessível.

6.2 Modelos de Linguagem (LLM)

Modelos de Linguagem de grande escala, como o Llama 3.1, são redes neurais treinadas em grandes volumes de dados textuais para entender e gerar linguagem natural. Esses modelos conseguem interpretar perguntas, contextualizar buscas e estruturar respostas coerentes. No sistema proposto, o LLM atua como núcleo interpretativo, recebendo as informações recuperadas pelo RAG e processadas pela camada CAG, para então gerar uma resposta final precisa, clara e adequada ao usuário.

6.3 RAG – Retrieval-Augmented Generation

RAG é uma técnica que combina recuperação de informações com geração de linguagem. Diferente de modelos puramente generativos, o RAG consulta uma base externa de conhecimento para encontrar conteúdos relevantes e fornecer respostas fundamentadas. Neste projeto, o RAG utiliza embeddings armazenados em um banco vetorial (Chroma) para localizar produtos semelhantes ao solicitado pelo usuário, garantindo precisão e atualização das informações exibidas pelo totem.

6.4 CAG – Context-Aware Generation

A camada CAG é um componente responsável por incorporar regras de contexto ao processo de geração de respostas. Ela interpreta o cenário da consulta (como ausência de um item específico, variações de cor ou tamanho e disponibilidade na loja) e reorganiza os resultados fornecidos pelo RAG para criar alternativas mais úteis. Assim, quando uma consulta retorna poucos ou nenhum produto, o CAG sugere opções similares, garantindo que o usuário receba respostas relevantes e acessíveis.

6.5 STT – Speech-to-Text

Speech-to-Text é o processo que converte áudio em texto. Tecnologias de STT permitem que sistemas compreendam comandos de voz emitidos pelo usuário. Neste projeto, utiliza-se o Whisper, modelo open-source amplamente reconhecido por sua precisão e capacidade de compreender variações de sotaque e ruídos ambientes. Ele é responsável por transformar a fala do usuário em texto que será processado pelo RAG, CAG e LLM.

6.6 TTS – Text-to-Speech

Text-to-Speech realiza a conversão de texto em áudio. A utilização de TTS garante acessibilidade, permitindo que o sistema forneça respostas de forma auditiva para pessoas com deficiência visual. O projeto utiliza o Coqui TTS, solução offline que produz voz natural e clara, possibilitando ao totem comunicar resultados e instruções com clareza e humanização.

6.7 Totens de Autoatendimento

Totens de autoatendimento são dispositivos interativos instalados em ambientes comerciais para auxiliar clientes sem necessidade de interação direta com atendentes. Eles permitem consultas rápidas, reduzem filas e otimizam processos internos. No contexto do varejo, esses totens são especialmente úteis para consulta de preços, disponibilidade de estoque e localização de produtos, aumentando a eficiência operacional e melhorando a experiência do consumidor.

6.8 Acessibilidade

A acessibilidade envolve garantir que sistemas, ferramentas e ambientes possam ser utilizados por qualquer pessoa, incluindo indivíduos com deficiência visual, auditiva, física ou cognitiva. No contexto deste projeto, acessibilidade significa permitir que clientes utilizem o totem por meio de comandos de voz e recebam respostas faladas de forma clara. A solução reforça o princípio da inclusão digital e física, removendo barreiras e promovendo autonomia dentro de espaços comerciais.

7 Metodologia

7.1 Levantamento de Requisitos Técnicos e Funcionais

Nesta etapa foram identificadas as necessidades do sistema, incluindo:

- interação por voz como principal meio de comunicação;
- acessibilidade para pessoas com deficiência visual;
- funcionamento local e offline;
- consulta precisa ao banco de produtos;
- respostas em texto e áudio;
- interface simples em tela touch.

Esses requisitos guiaram todas as decisões técnicas do projeto.

7.2 Seleção das Tecnologias

Com base nos requisitos, definiu-se um conjunto de tecnologias compatíveis, eficientes e gratuitas:

- Whisper para reconhecimento de fala (STT);
- Chroma como banco vetorial para RAG;
- Llama 3.1 como modelo de linguagem (LLM) via Ollama;
- Coqui TTS para síntese de voz;
- FastAPI como backend de integração;
- SQLite como banco local de produtos;
- HTML/JavaScript para o frontend em tela touch.

Essas tecnologias foram escolhidas por funcionarem offline, possuírem boa documentação e atenderem às necessidades de desempenho do totem.

7.3 Estruturação do Banco de Dados (SQLite)

Foi criada uma base de dados contendo atributos essenciais dos produtos, como nome, categoria, cor, tamanho, preço e localização dentro da loja. A persistência local permite rapidez nas consultas e dispensa infraestrutura adicional.

7.4 Implementação da Camada CAG (Context-Aware Generation)

A camada CAG foi desenvolvida para analisar os resultados do RAG, aplicar regras de contexto e tomar decisões como sugerir produtos semelhantes quando a busca retornar resultados insuficientes. Essa etapa garante que o sistema apresente alternativas úteis e contextualizadas.

7.5 Integração do LLM (Llama 3.1)

O Llama recebe como entrada o texto transcrito, os resultados do RAG e as informações tratadas pelo CAG. Sua função é interpretar a intenção do usuário e gerar uma resposta estruturada, clara e adequada.

7.6 Implementação dos Módulos de Entrada e Saída de Áudio

- O módulo STT converte a fala do usuário em texto utilizando Whisper.
- O módulo TTS converte a resposta final do sistema em áudio por meio do Coqui TTS.

Esses dois elementos garantem acessibilidade total para usuários com deficiência visual.

7.7 Desenvolvimento do Backend (FastAPI)

Foi implementado um backend organizado em rotas responsáveis por:

- receber o áudio do usuário;
- processar o fluxo STT → RAG → CAG → LLM → TTS;
- consultar o banco SQLite;
- retornar o produto encontrado e o arquivo de áudio gerado.

O backend atua como núcleo do sistema, integrando todas as partes.

7.8 Desenvolvimento do Frontend (HTML/JS)

Criou-se uma interface em tela fullscreen com suporte a touch. A interface apresenta botões grandes, textos ampliados e navegação simples. O usuário pode iniciar a consulta por voz, visualizar o nome do produto encontrado e ouvir a resposta sintetizada pelo sistema.

7.9 Integração do Protótipo

Após validar cada módulo individualmente, foi realizada a integração completa, permitindo que o usuário fale com o totem e receba a resposta de forma contínua e acessível.

7.10 Testes Funcionais e Critérios de Avaliação

Foram definidos testes focados em:

- Precisão do reconhecimento de fala;
- Relevância dos resultados encontrados pelo RAG;
- Comportamento do CAG quando não há itens disponíveis;
- Clareza das respostas geradas pelo LLM;
- Qualidade do áudio sintetizado;
- Usabilidade da interface touch.

Os testes visam garantir eficiência, acessibilidade e estabilidade.

7.11 Documentação das Etapas

Todo o processo de construção, testes, arquitetura e integrações foi documentado para permitir futuras expansões e manutenção do projeto.

8 Arquitetura do Sistema

Arquitetura do Sistema




Foto 1: Arquitetura do Sistema em Diagrama

A arquitetura do sistema foi projetada para integrar múltiplas tecnologias de Inteligência Artificial de forma eficiente, garantindo operação local e acessível. O fluxo central combina reconhecimento de fala, recuperação inteligente de informações, interpretação contextual e síntese de áudio, permitindo interação natural entre o usuário e o totem.

O sistema é dividido em quatro camadas principais: entrada (captura de voz), processamento (STT, RAG, CAG, LLM), gerenciamento de dados (SQLite e Chroma) e saída (resposta em texto e voz). A comunicação entre essas camadas é realizada por meio do backend desenvolvido com FastAPI.

8.1 Camada de Entrada – Captura de Áudio

O processo inicia quando o usuário interage com o totem por meio de um comando de voz. O microfone embutido captura o áudio e o envia ao backend. Essa etapa é responsável por fornecer o material bruto que será interpretado pelo sistema.

8.2 Módulo de Reconhecimento de Fala (STT – Whisper)

O áudio capturado é processado pelo Whisper, que converte a fala em texto com alta precisão. Essa transcrição é a base para todas as etapas seguintes. O uso do Whisper garante funcionamento offline, entendimento de sotaques e robustez em ambientes de ruído moderado.

8.3 Mecanismo de Busca Inteligente (RAG – Retrieval-Augmented Generation)

Após a transcrição, o texto é enviado ao módulo RAG, responsável por identificar produtos relevantes. O RAG consulta a base vetorial criada no Chroma, onde cada produto está representado por seus embeddings. Esse mecanismo permite encontrar itens semelhantes ao pedido do usuário, mesmo em consultas imprecisas ou incompletas.

8.4 Camada de Interpretação de Contexto (CAG – Context-Aware Generation)

Os resultados recuperados pelo RAG passam por uma camada de decisão contextual. O CAG analisa se os produtos encontrados são suficientes e toma decisões quando ocorrem situações como:

- nenhum produto encontrado;
- produto encontrado, mas com variações insuficientes (cor, tamanho etc.);
- necessidade de sugerir alternativas similares.

O CAG garante que o sistema sempre responda de forma útil, mesmo em cenários de baixa correspondência.

8.5 Modelo de Linguagem (LLM – Llama 3.1)

Com base nos resultados processados pelo RAG e CAG, o LLM interpreta a intenção do usuário e gera uma resposta estruturada. O Llama 3.1, executado localmente via Ollama, recebe como entrada o texto original do usuário, os produtos encontrados e o contexto analisado pelo CAG, devolvendo um texto coerente e claro.

8.6 Banco de Dados de Produtos (SQLite)

O SQLite armazena as informações estruturadas dos produtos disponíveis na loja, como nome, categoria, preço, cor e localização. Esse banco é consultado pelo backend sempre que necessário e serve como base primária para geração dos embeddings usados no Chroma.

8.7 Base Vetorial (Chroma)

O banco vetorial armazena embeddings gerados a partir das descrições dos produtos. Ele é fundamental para o funcionamento do RAG, permitindo buscas por similaridade e garantindo resultados mais inteligentes do que simples consultas textuais.

8.8 Módulo de Síntese de Voz (TTS – Coqui TTS)

Após a geração do texto final pelo LLM, o módulo TTS converte a resposta em áudio. Essa etapa é essencial para acessibilidade, permitindo que pessoas com deficiência visual recebam informações de forma clara e auditiva.

8.9 Camada de Saída – Interface do Totem

A resposta final é apresentada ao usuário de duas formas:

- visualmente, no display touch fullscreen;
- em áudio, reproduzido pelo TTS.

A interface foi desenvolvida em HTML/JavaScript, com elementos grandes e navegação simples, garantindo interatividade por toque e boa experiência para todos os usuários.

8.10 Backend (FastAPI) como Núcleo de Integração

Todas as etapas — STT, RAG, CAG, LLM, TTS e consultas ao SQLite — são coordenadas pelo backend. O FastAPI recebe as requisições, executa o pipeline completo e retorna as respostas para a interface de forma rápida e eficiente.

9 Cronograma do Projeto

9.1 janeiro – Planejamento e Definição do Escopo

- Identificação do problema e necessidades de acessibilidade.
- Definição do público-alvo.
- Análise de soluções existentes no mercado.
- Estudo inicial das tecnologias possíveis.
- Escolha da arquitetura geral do sistema (IA offline, STT, RAG, CAG, LLM, TTS).
- Delimitação do escopo da primeira etapa (Pré-Banca).

9.2 fevereiro – Pesquisa e Fundamentação Teórica

- Estudo aprofundado de IA, LLM, RAG, CAG, STT e TTS.
- Pesquisa sobre totens de autoatendimento e acessibilidade no varejo.
- Coleta de referências acadêmicas e definição do referencial teórico.
- Redação dos capítulos introdutórios da documentação.

9.3 março – Arquitetura do Sistema e Modelagem Técnica

- Estruturação da arquitetura geral do projeto.
- Modelagem do pipeline STT → RAG → CAG → LLM → TTS.
- Desenho dos fluxos de interação do usuário com o totem.
- Definição do banco de produtos em SQLite.
- Planejamento e estruturação da base vetorial (Chroma).
- Revisão da documentação para pré-banca.

9.4 abril – Desenvolvimento dos Módulos Individuais

- Implementação do reconhecimento de voz com Whisper.
- Geração dos embeddings e criação da base vetorial no Chroma.
- Desenvolvimento da camada CAG (Context-Aware Generation).
- Integração inicial do modelo Llama via Ollama.
- Implementação da síntese de voz com Coqui TTS.
- Início da construção do backend com FastAPI.

9.5 maio – Desenvolvimento da Interface e Integração Inicial

- Criação do frontend em HTML/JS em fullscreen.
- Implementação de elementos acessíveis para toque.
- Comunicação do frontend com o backend.
- Testes iniciais do fluxo: fala → texto → busca → resposta.
- Ajustes no pipeline para garantir coerência entre os módulos.
- Preparação para apresentação da Pré-Banca.

9.6 junho – Integração Completa do Protótipo

- Finalização da integração dos módulos STT, RAG, CAG, LLM e TTS.
- Implementação do fluxo completo do sistema.
- Otimização do tempo de resposta e usabilidade.
- Testes funcionais e correções de bugs.
- Coleta de feedback para melhorias.

9.7 julho – Testes Avançados e Refinamentos

- Testes com usuários simulados.
- Avaliação de precisão de reconhecimento de fala.
- Avaliação da relevância dos resultados do RAG e do comportamento do CAG.
- Ajustes de interface para acessibilidade.
- Aperfeiçoamento da experiência do usuário.

9.8 agosto – Documentação Final e Preparação da Banca

- Revisão completa de toda a documentação.
- Criação dos diagramas finais da arquitetura e fluxos.
- Preparação dos slides para CONIC e Banca Final.
- Ajustes finais no protótipo para demonstração.

10 Considerações Finais

As etapas desenvolvidas até o momento permitiram consolidar a base técnica e conceitual necessária para a construção do totem de autoatendimento acessível. Foram definidos o problema central, o público-alvo, a justificativa e os objetivos do projeto, além da seleção das tecnologias que compõem a arquitetura do sistema. Também foram estabelecidos o fluxo de funcionamento, a metodologia de desenvolvimento e o cronograma previsto, permitindo uma visão clara e organizada do avanço do trabalho.

A fundamentação teórica e o planejamento técnico demonstram que a solução proposta é viável, relevante e capaz de promover maior inclusão para pessoas com deficiência visual no ambiente varejista. O próximo período será dedicado à implementação progressiva dos módulos, integração das tecnologias e validação do protótipo funcional, consolidando o sistema para apresentação nas próximas etapas da banca.

Com isso, esta entrega parcial conclui a fase de planejamento e estruturação do projeto, estabelecendo os alicerces necessários para a continuidade do desenvolvimento e para a evolução do totem acessível até sua versão final.

11 Referências Bibliográficas

META. Llama 3.1: Open Large Language Model. 2024. Disponível em: <https://www.meta.com/ai>. Acesso em: 25 nov. 2025.

OPENAI. Whisper: Robust Speech Recognition via Large-Scale Weak Supervision. 2022. Disponível em: <https://github.com/openai/whisper>. Acesso em: 25 nov. 2025.

JILA, Mirco; COQUI AI. Coqui TTS: A Deep Learning Toolkit for Text-to-Speech. 2023. Disponível em: <https://github.com/coqui-ai/TTS>. Acesso em: 25 nov. 2025.

CHROMA DB. Chroma: The AI-native Vector Database. 2023. Disponível em: <https://www.trychroma.com>. Acesso em: 25 nov. 2025.

OLIVER, Noah et al. Ollama: Local Large Language Model Runner. 2023. Disponível em: <https://ollama.com>. Acesso em: 25 nov. 2025.

PYTHON SOFTWARE FOUNDATION. FastAPI Documentation. 2024. Disponível em: <https://fastapi.tiangolo.com>. Acesso em: 25 nov. 2025.

SQLITE. SQLite Documentation. 2024. Disponível em: <https://www.sqlite.org>. Acesso em: 25 nov. 2025.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. Deep Learning. MIT Press, 2016.

RUSSELL, Stuart; NORVIG, Peter. Artificial Intelligence: A Modern Approach. 4. ed. Pearson, 2021.

NIELSEN, Jakob. Usability Engineering. Morgan Kaufmann, 1993.

W3C. Web Content Accessibility Guidelines (WCAG) 2.1. 2018. Disponível em: <https://www.w3.org/WAI>. Acesso em: 25 nov. 2025.

COUTO, Rafael. Totens de Autoatendimento e Experiência do Usuário. Revista Brasileira de Design e Interação, v. 12, n. 2, p. 45-59, 2021.